BigQuery Profiler

고객이 직접 실행하는 경량 도구로, BigQuery 사용량 메타데이터를 수집해 Databricks가 레이크하우스에서 동일한 워크로드를 모델링할 수 있게 합니다. BigQuery `INFORMATION_SCHEMA` 뷰만 읽으며, **고객의 쿼리 결과나 테이블 데이터에는 접근하지 않습니다**.

프로파일러는 귀사의 BQ 프로젝트를 대상으로 실행되어 CSV를 담은 작은 zip 파일을 만듭니다. 이 zip 파일을 Databricks 담당자에게 보내 주시면 됩니다.

준비 사항

항목	내용
GCP 접근 권한	분석할 프로젝트 전체에 BigQuery 읽기 권한이 있는 사용자 계정 또는 서비스 계정
실행 환경	GCP Cloud Shell(권장 — 로컬 설정 불필요) 또는 Python 3.9 이상과 `gcloud` CLI가 설치·인증된 로컬 PC
소요 시간	포함하는 `(프로젝트 × 리전)` 조합 수에 따라 보통 5~20분

IAM 권한

프로파일러를 실행하는 계정에는 분석 대상 프로젝트에 대해 다음 BigQuery 권한이 필요합니다.

- `bigquery.datasets.get` — *`INFORMATION_SCHEMA.SCHEMATA.ddl`에서 각 데이터셋의 스토리지 과금 방식(logical / physical)도 읽습니다. 이는 데이터셋 메타데이터입니다. 이 권한이 없으면 모든 데이터셋이 logical로 분류되어, 실제로 physical 과금을 쓰는 데이터셋의 스토리지 비용 예측이 틀어집니다.*
- `bigquery.tables.get`
- `bigquery.tables.list`
- `bigquery.routines.get`
- `bigquery.routines.list`
- `bigquery.jobs.create`
- `bigquery.jobs.listAll`
- `bigquery.capacityCommitments.list`
- `bigquery.readsessions.create`
- `bigquery.readsessions.getData`

가장 간단한 방법은 프로젝트에 **BigQuery 관리자** 역할(`roles/bigquery.admin`)을 부여하는 것으로, 위 권한이 모두 포함됩니다. 최소 권한 커스텀 역할이 필요하다면 위 목록이 정확한 권한 집합입니다.

설치

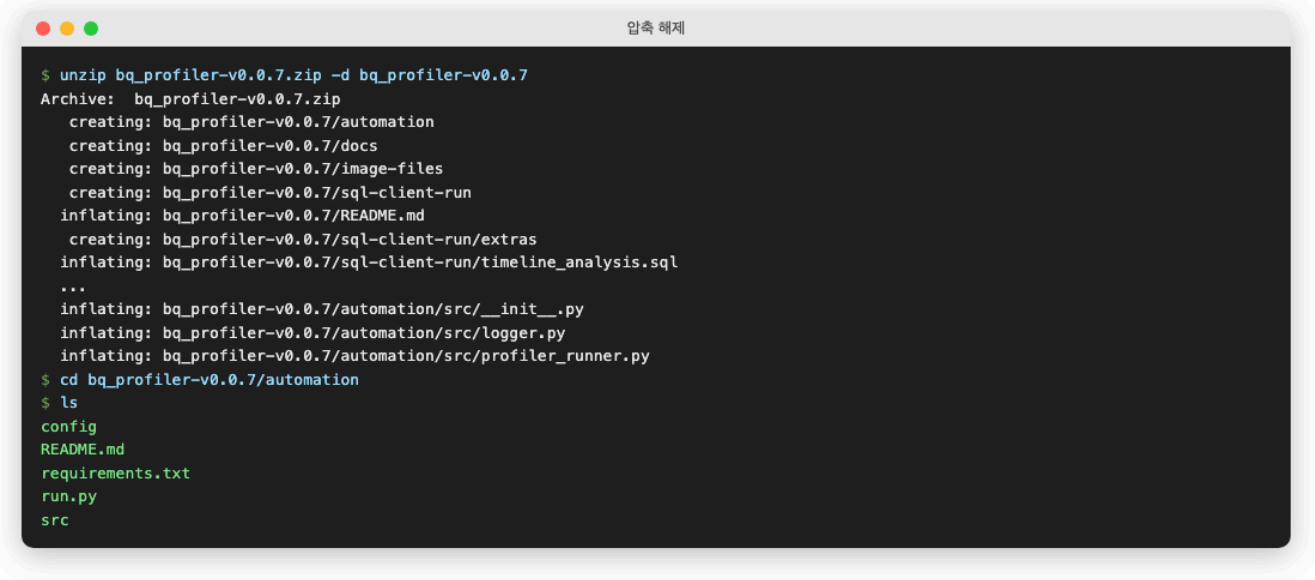
1. 프로파일러 패키지 받기

Databricks 담당자가 zip 파일(예: `bq_profiler-v0.0.7.zip`)을 보내 드립니다.

2. GCP Cloud Shell에 업로드 (권장)

1. GCP 콘솔을 열고 오른쪽 위의 **Cloud Shell 활성화** 아이콘을 클릭합니다.
2. Cloud Shell의 ⋮ **메뉴** → **업로드** 또는 편집기의 파일 패널로 zip 파일을 업로드합니다.
3. 압축을 풉니다.

```
unzip bq_profiler-v0.0.7.zip -d bq_profiler-v0.0.7
cd bq_profiler-v0.0.7/automation
```



압축 해제 화면

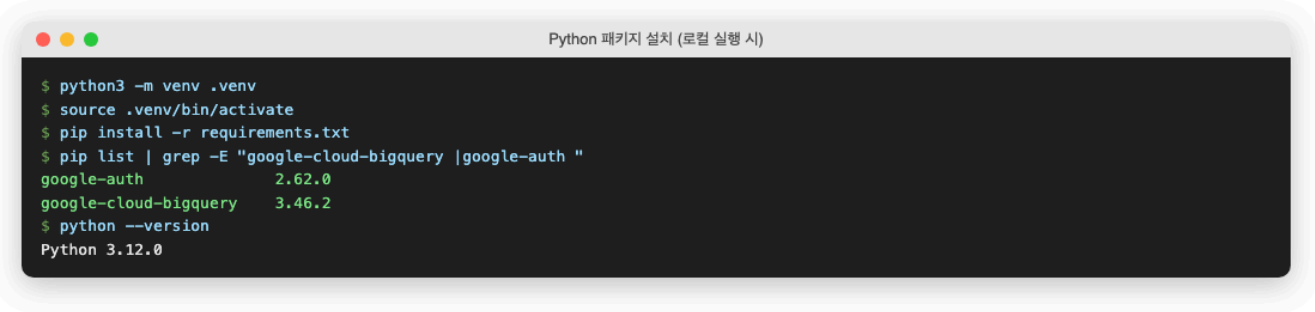
Cloud Shell을 권장하는 이유는 인증이 자동으로 처리되고(로그인한 GCP 계정 사용) Python이 미리 설치되어 있기 때문입니다.

대안: 로컬에서 실행

Cloud Shell을 쓸 수 없다면 로컬 PC에서 실행합니다.

```
# 인증
gcloud auth login
gcloud auth application-default login
gcloud config set project YOUR-BQ-PROJECT-ID

# Python 패키지 설치
cd bq_profiler-v0.0.7/automation
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
```



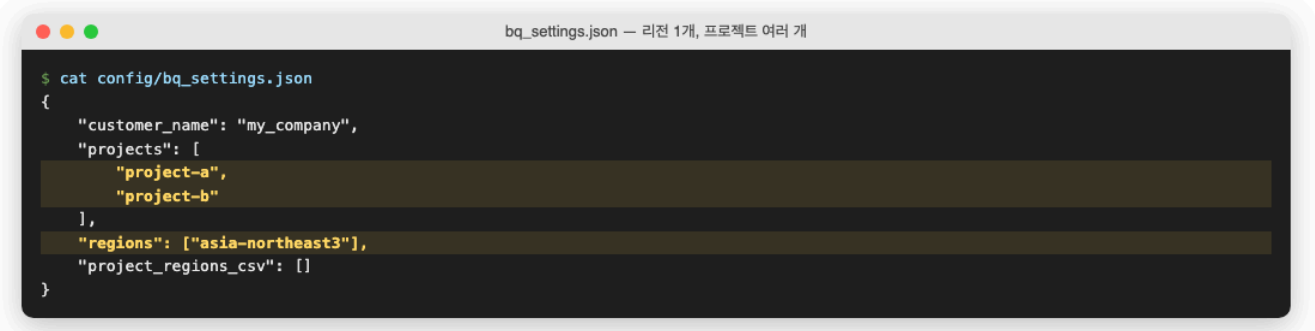
Python 패키지 설치 화면

설정

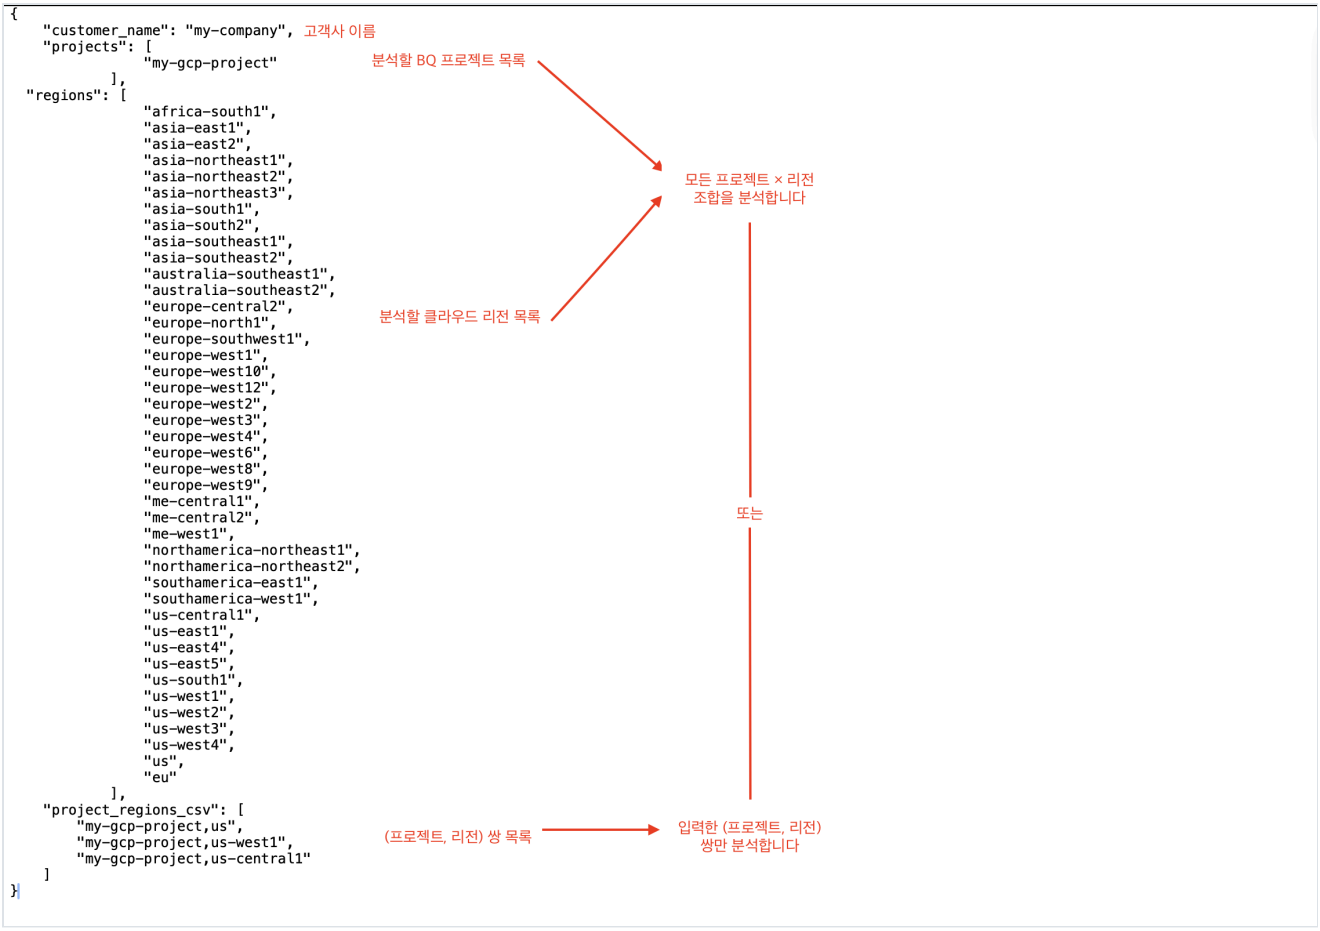
`automation/config/bq_settings.json` 파일에 귀사 정보를 입력합니다. 가장 일반적인 경우인 **리전 1개에 프로젝트가 여러 개**인 예시입니다.

```
{
    "customer_name": "your_company",
    "projects": [
        "project-a",
        "project-b",
        "project-c"
    ],
    "regions": ["asia-northeast3"],
    "project_regions_csv": []
}
```

- **`customer_name`** — 회사를 나타내는 짧은 식별자(소문자, 공백 없음). 결과 zip 파일의 이름이 됩니다.
- **`projects`** — 분석할 BQ 프로젝트 ID를 모두 나열합니다.
- **`regions`** — BQ 데이터가 있는 리전. 서울만 쓰신다면 `["asia-northeast3"]`, US 멀티 리전은 `"us"`입니다. 기본 파일에는 지원되는 모든 리전이 들어 있으므로, 사용하는 리전만 남기고 지워 주세요. 그대로 두어도 동작하지만 리전 수만큼 실행 시간이 늘어납니다.
- **`project_regions_csv`** — 비워 둡니다(`[]`). 이 경우 `projects × regions`의 모든 조합(위 예시는 프로젝트 3개 × 리전 1개 = 3개)을 분석합니다. 프로젝트마다 리전이 다를 때만 `"project_id,region"` 형식으로 쌍을 직접 나열하며, 값이 있으면 `projects`·`regions`보다 우선합니다.



실제 테스트에 사용한 설정 (서울 리전 1개, 프로젝트 2개)



참고: 두 가지 지정 방식 — 프로젝트 × 리전 전체 조합 또는 (프로젝트, 리전) 쌍 직접 지정

실행

`automation/` 디렉터리에서 실행합니다.

```
python run.py
```

옵션 (대부분은 필요하지 않습니다)

플래그	용도
`--cred-file=/path/to/key.json`	GCP 서비스 계정 JSON 키 경로. Cloud Shell이나 `gcloud auth` 를 사용하면 생략합니다.
`--num-threads=N`	동시에 실행할 SQL 수입니다. 기본값은 10입니다.

스크립트는 다음 순서로 동작합니다.

1. 설정한 각 `(project, region)` 에 맞춰 SQL 템플릿을 컴파일합니다.
2. BQ에서 실행합니다.
3. CSV 결과를 `bq_profiler-v0.0.7/output/runs/<customer_name>/` 에 저장합니다.
4. 완료되면 전체를 `bq_profiler-v0.0.7/output/<customer_name>.zip` 으로 묶습니다.

프로젝트·리전별 진행 상황이 표시됩니다. `Output saved in zipped archive: ...`가 보이면 실행이 끝난 것입니다.

python run.py 실행

```
$ python run.py
Compiling sql for project.regions...
project-b.region-asia-northeast3 Done
project-a.region-asia-northeast3 Done

Executing sql...

Execution finished

Generating zip archive...

Output saved in zipped archive: /home/you/bq_profiler-v0.0.7/output/my_company.zip
```

실행 화면 (프로젝트 2개 × 서울 리전, 약 30초 소요)

실행 후 로그 확인

권한이 없는 프로젝트가 있어도 화면에는 오류가 표시되지 않고 정상 종료처럼 보입니다. 실행이 끝나면 `automation/`에서 한 단계 위(`cd ..`)로 이동해 로그에 오류가 있는지 확인해 주세요.

```
grep -c "] ERROR:" output/logs/*.log
```

결과가 `0`이면 정상입니다. 0이 아니면 아래처럼 어느 프로젝트에서 어떤 권한이 부족한지 확인한 뒤, 해당 프로젝트에 IAM 권한을 부여하고 다시 실행해 주세요.

실행 후 로그 확인 (권한이 없는 프로젝트가 있는 경우)

```
$ grep -c "] ERROR:" output/logs/*.log
10
$ grep "] ERROR:" output/logs/*.log | grep -o "Access Denied: Table [^ ]*" | sort -u
Access Denied: Table project-b:region-asia-northeast3.INFORMATION_SCHEMA.JOBS_TIMELINE:
Access Denied: Table project-b:region-asia-northeast3.INFORMATION_SCHEMA.JOBS:
Access Denied: Table project-b:region-asia-northeast3.INFORMATION_SCHEMA.TABLE_STORAGE:
$ grep "] ERROR:" output/logs/*.log | grep -o "required permissions ([^)]*)" | sort -u
required permissions ('bigquery.jobs.listAll' permission(s)
required permissions ('bigquery.tables.get', 'bigquery.tables.list' permission(s)
```

예: project-b에 bigquery.jobs.listAll 등 권한이 없어 일부 조회가 실패한 경우

결과 전달

`bq_profiler-v0.0.7/output/<customer_name>.zip`을 내려받습니다(Cloud Shell: 파일 패널에서 마우스 오른쪽 버튼 → 다운로드, 로컬: 해당 폴더에서 바로 확인).

결과 zip 확인

```
$ ls -lh output/my_company.zip
-rw-r--r--@ 10K Nov 2 17:22 output/my_company.zip
$ unzip -l output/my_company.zip | tail -1
     7018                    27 files
```

결과 zip 확인 화면

이 zip 파일 하나를 지금까지 사용해 온 채널(Slack 파일 공유, 이메일 첨부, 고객용 Drive 폴더 등)로 Databricks 담당자에게 공유해 주세요.

이것으로 끝입니다. 나머지 분석은 Databricks에서 진행합니다.

프로파일러가 조회하는 항목

모든 수집은 `INFORMATION_SCHEMA` 뷰에서 이루어지며, 프로파일러는 실제 테이블을 읽지 않습니다.

- `JOBS_TIMELINE_BY_*` — Job별 슬롯 사용량, 실행 시간, 워크로드 유형
- `RESERVATIONS_TIMELINE` / `RESERVATION_CHANGES` — 용량 약정 및 예약 이력
- `TABLE_STORAGE` — 현재 스토리지 사용량(크기만, 내용은 제외)
- `SCHEMATA` — `storage_billing_model` 옵션(logical / physical)을 포함한 데이터셋 수준 메타데이터
- `STREAMING_TIMELINE_*` / `WRITE_API_TIMELINE_*` — 스트리밍 적재량

고객의 쿼리 텍스트, 쿼리 결과, 테이블 내용, 개인정보(PII)는 읽지 않습니다. 스토리지 과금 방식은 `INFORMATION_SCHEMA.SCHEMATA`의 `ddl` 컬럼에서 가져오며, 이는 데이터셋 메타데이터입니다(`bigquery.datasets.get` 권한에 포함). 프로파일러의 SQL은 귀사의 데이터 테이블에 대해 `SELECT`를 실행하지 않으며, 테이블 데이터 읽기 권한(`bigquery.tables.getData`)도 요청하지 않습니다. 보안팀 검토가 필요하시면 전체 SQL 템플릿을 `sql-client-run/` 폴더에서 확인하실 수 있습니다.

문제 해결

증상	조치
로그에 **`Access Denied`** 오류	화면에는 표시되지 않으므로 "실행 후 로그 확인"으로 찾습니다. 위에 나열한 IAM 권한을 확인합니다. 커스텀 역할이 동작하지 않으면 `roles/bigquery.admin`을 사용해 보세요.
`Auth credentials not found`	`gcloud auth application-default login`을 실행하거나 `--cred-file=/path/to/key.json`을 지정합니다.
특정 리전의 결과가 비어 있음	정상입니다. 모든 리전에 데이터가 있는 것은 아니며, zip 파일은 그대로 완전합니다.
특정 리전에서 멈춘 것처럼 보임	사용량이 많은 프로젝트에서는 이력이 많은 일부 쿼리가 10분 이상 걸릴 수 있습니다. 실제로 멈췄다면(30분 이상) Ctrl+C로 중단하고 해당 리전을 뺀 뒤 다시 실행하고, 수집된 결과를 공유해 주세요.

그 밖의 문제가 있으면 Databricks 담당자에게 문의해 주세요.